

Pénzügyi adatelemzés 3. Házi Feladat

Beadási határidő: 2025. 11. 23. 23:59, a Moodle-ben kijelölt helyre feltöltve, 1 darab pdf fájlban, ahol a fájl nevében legyen benne a készítő vezetékeve a következő formátumban: „KOVACS.pdf”.

A házi feladatot egyénileg készítsétek el. Nevet, Neptun kódot és email címet a házi feladat címlapján is tüntessétek fel!

A dolgot vezetői beszámoló (*executive summary*¹) stílusban, röviden, tömören, gyorsan áttekinthető módon (max 4 oldal), a készítsétek el. Törekedjete a világos, lényegre törő megfogalmazásra, az üzenet átadását a dolgozat vizuális megjelenítése is segítse. Használjatok ábrákat, táblázatokat, színeket.

Másolás gyanúja esetén minden érintett hallgató nulla pontot kap!

Ezzel a házi feladattal legfeljebb **15 pont** szerezhető.

Cél: Predikciós modellszelekció demonstrálása lakáspiaci adatokon.

Célváltozó: Price

Készíts egy elemzést a következő kérdésekre válaszolva a következő lakásadatbázis segítségével:

<https://www.kaggle.com/datasets/yasserh/housing-prices-dataset?resource=download>

Az elemzés során véletlenszerűen 80-20% arányban oszd fel a mintádat work (train - 64% + validation -16%) és holdout (teszt) részre. Építs 8 különböző komplexitású modellt. Figyeld arra modellválasztásnál, hogy ez egy predikciós feladat, és a cél a különböző modell szelekciós megoldások bemutatása, ami akkor tud könnyen prezentálható lenni, hogyha lényeges különbség van az egyes modellek között.

1) **Hasonlítsd össze a következő 3 modellszelekciós eljárást** (melyik modellt választja ki, hogyan alakul a train és validation rész RMSE értéke az egyes modellek esetén). Próbáld meg az eredményeket, táblázat, és ábra segítségével tömören bemutatni.

A) *Direkt*: modellek fit a **train**-en; kiválasztás **validation RMSE** alapján (CV nélkül).

B) *Indirekt*: modellek fit **train+validation**-on; kiválasztás **BIC** (és később AIC) alapján.

C) *Regularizáció*: LASSO fit **train+validation**-on; λ kiválasztása **validation RMSE** (később 5-fold CV) alapján.

Mindhárom eljárás **kiválasztott** modelljével készíts előrejelzést a **holdout/test** halmazra, és hasonlítsd össze a holdout RMSE-ket (elsődleges), plusz MAE-t (másodlagos).

2) **Keresztvalidációs kiterjesztés** Ismételd meg az A) és C) eljárást **5-fold CV**-val a kiválasztási lépésben (preprocess *fold-on belül!*); hasonlítsd össze, mennyiben változik a holdout teljesítmény.

3) **AIC vs. BIC** A B) eljárást futtasd AIC-val is; vitasd meg az eltérést (modellméret, illeszkedés, holdout teljesítmény).

4) **Ismétléses értékelés (stabilitás)** Véletlenszerű szétválasztást **100x** ismételd; jelentsd a kiválasztott modellek arányát és a holdout metrikák **átlagát \pm szórását** táblázatban és ábrán.

A probléma megoldása során próbáld meg minél több szempontot figyelembe véve válaszolni a kérdésre. Használd az órán tanult koncepciókat!

Mit tartalmazzon a dokumentum:

1–2 ábra: kiválasztási görbék (pl. RMSE vs. modellindex/ λ), és a 100x ismétlés eloszlásai/boxplotjai.

2–3 táblázat: train/val RMSE per modell; AIC/BIC rangsorok; holdout eredmények (átlag \pm sd).

Rövid módszertani indoklás: miért ez a modellkészlet; előfeldolgozás lépések;

Melléklet: részletes modell- és hiperparaméter-leírás

¹ http://en.wikipedia.org/wiki/Executive_summary